



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD POLITÉCNICA

DISEÑO E IMPLEMENTACIÓN DE UN SISTEMA DE
RECOMENDACIÓN HÍBRIDO BASADO EN TÉCNICAS
COLABORATIVAS, EVOLUTIVAS Y DE CONTENIDO.

TRABAJO FINAL DE GRADO

JOSÉ LUIS JUNIOR GUTIÉRREZ AGÜERO

SAN LORENZO – PARAGUAY

2025



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD POLITÉCNICA

DISEÑO E IMPLEMENTACIÓN DE UN SISTEMA DE
RECOMENDACIÓN HÍBRIDO BASADO EN TÉCNICAS
COLABORATIVAS, EVOLUTIVAS Y DE CONTENIDO.

TRABAJO FINAL DE GRADO

Autor:

José Luis Junior Gutiérrez Agüero

Tutor:

D.Sc Ing. Christian von Lücken

SAN LORENZO – PARAGUAY

2025

Dedicatoria

Dedico este trabajo a mis padres, cuyo apoyo constante y dedicación hicieron posible que pudiera avanzar y concretar cada uno de mis planes y objetivos en esta etapa de mi vida, y quienes además han sido un ejemplo permanente de esfuerzo y perseverancia.

Junior Gutiérrez

Agradecimientos

Deseo expresar mi especial agradecimiento a mi tutor, D.Sc. Ing. Christian von Lücken, por su orientación, dedicación y apoyo constante durante la realización de este trabajo.

A mis amigos de la Facultad Politécnica, con quienes compartí experiencias que marcaron mi vida universitaria: Francisco Sanabria, René Pauls, Alejandro Cabral, Iván Weiss, Guillermo Pamplona, Diego Duarte Cardozo, Carlos Urdapilleta, Guillermo Rodas, Christian Ortellado, Romina Alfonso, Alejandra Lezcano, Camila Maidana, Diego Duarte Centurión, Rodolfo Vergara, Alejandro Marín, Javier López, Guillermo Paiva, Jessica Alarcón, Ara Núñez, Emilio Ginzo, Marcos Aurelio, Matías Winter y César Rodas.

A mis amigos de siempre, cuyo acompañamiento ha sido fundamental en todas las etapas de mi vida: Edgar Ramírez, Héctor González, César Escobar, Pamela Brítez, Wilson Medina, Francisco Zarratea, Alexander Garbett, José Burgos y Santiago Amarilla.

A mis familiares, por su cariño incondicional y apoyo permanente: Tía Ruth, Tío Santi, Tía Mabel, Tío Derlis, Ramonita, Rania, Eldon Wiens, Vanessa, David, Tía Rilsí, Claudio, Mauri y Rossana.

A los excelentes amigos que hice durante mi intercambio en Wichita State University gracias al Comité Paraguay Kansas: Anabella Bottino, Felipe Duarte, Nicolás Carreras, Miguel Villagra, Evan Mansil, Mahesh y Treven Rowland.

Finalmente, a mis amigos de eTica y Banco Familiar, quienes hicieron que mi ingreso al mundo profesional sea una experiencia extraordinaria.

Resumen

Este trabajo presenta el diseño, implementación y evaluación de una extensión del algoritmo *Hybrid Probabilistic Multiobjective Evolutionary Algorithm* (HP-MOEA), aplicado al dominio de los sistemas de recomendación. El algoritmo original combina filtrado colaborativo basado en usuarios con algoritmos evolutivos multiobjetivo, optimizando simultáneamente ganancia y novedad para mitigar el problema del inicio frío.

La contribución principal de este trabajo consiste en la incorporación de un componente basado en contenido que pondera la métrica de novedad en función de la afinidad temática entre usuarios e ítems. Para su validación, se empleó el dataset *MovieLens*, un *benchmark* estándar en la investigación de sistemas de recomendación. La implementación del algoritmo se desarrolló en el lenguaje de programación *Python*, empleando la biblioteca *Pymoo* para la implementación de los algoritmos evolutivos *NSGA-II* y *SMS-EMOA*. Además, se utilizó *NumPy* para desarrollar estructuras de datos internas que optimizan la ejecución del algoritmo y *Pandas* para la lectura y manipulación del conjunto de datos utilizado en los experimentos.

Los resultados experimentales muestran que el algoritmo modificado mantiene un rendimiento competitivo en métricas de convergencia como la distancia generacional (GD) y su versión inversa (IGD), al tiempo que logra una mejora significativa en el hipervolumen, lo que refleja una frontera de Pareto más amplia y soluciones mejor distribuidas.

La propuesta demuestra que la integración de información de contenido permite mejorar la calidad de las recomendaciones y ofrece un aporte concreto en el tratamiento del problema del inicio frío.

Abstract

This work presents the design, implementation, and evaluation of an extension of the *Hybrid Probabilistic Multiobjective Evolutionary Algorithm* (HP-MOEA), applied to the domain of recommender systems. The original algorithm combines user-based collaborative filtering with multiobjective evolutionary algorithms, simultaneously optimizing *gain* and *novelty* to mitigate the cold-start problem.

The main contribution of this work lies in the incorporation of a content-based component that weights the novelty metric according to the thematic affinity between users and items. For validation purposes, the *MovieLens* dataset was used, which is a standard benchmark in recommender systems research. The implementation was carried out in the *Python* programming language, using the *Pymoo* library to implement the evolutionary algorithms *NSGA-II* and *SMS-EMOA*. In addition, *NumPy* was used for managing internal data structures that optimize algorithm execution, and *Pandas* for reading and manipulating the dataset used in the experiments.

Experimental results show that the modified algorithm maintains competitive performance in convergence metrics such as Generational Distance (GD) and Inverted Generational Distance (IGD), while achieving a significant improvement in the hypervolume metric, indicating a broader Pareto front and better-distributed solutions.

The proposed approach demonstrates that integrating content information enhances recommendation quality and provides a concrete contribution to addressing the cold-start problem.

Índice general

Dedicatoria	II
Agradecimientos	III
Resumen	IV
Abstract	V
Índice general	VI
Índice de figuras	VIII
Índice de cuadros	IX
Acrónimos y símbolo	X
1. Introducción	1
1.1. Objetivos	2
1.2. Hipótesis	2
1.3. Metodología resumida	3
1.4. Organización del trabajo	3
2. Marco teórico	4
2.1. Sistemas de recomendación	4
2.1.1. Objetivos	7
2.1.2. Modelos básicos de los Sistemas de recomendación	8
2.1.3. Problemas conocidos	9

2.1.4.	Breve historia y actualidad de los Sistemas de recomendación	10
2.2.	Optimización multiobjetivo con algoritmos evolutivos	11
2.2.1.	Optimización Multiobjetivo	11
2.2.2.	Algoritmos genéticos	13
2.2.3.	Algoritmos evolutivos multiobjetivos	15
2.3.	Trabajos relacionados	17
3.	HP-MOEA	21
3.1.	Filtrado colaborativo basado en usuarios	21
3.2.	MOEA	23
3.2.1.	Objetivos	23
3.2.2.	Individuos y población	25
3.2.3.	Operadores genéticos	26
3.2.4.	Bucle principal	28
4.	Implementación y algoritmo propuesto	30
4.1.	Implementación	30
4.1.1.	Análisis experimental del filtrado colaborativo	31
4.1.2.	Primeros resultados	32
4.2.	Limitaciones del enfoque original	34
4.3.	Perfiles de usuarios	35
4.4.	Modificación en la función objetivo	35
4.5.	Resultados	37
4.6.	Pruebas con distintos tamaños de población	38
5.	Conclusiones	42
5.1.	Trabajos futuros	42

Índice de figuras

2.1. Ejemplo de filtrado colaborativo basado en usuarios [14].	8
2.2. Frente de Pareto en un problema multiobjetivo. [20]	12
2.3. Ciclo típico de un algoritmo genético [2].	14
2.4. Procedimiento del NSGA-II [8].	16
2.5. Procedimiento del SMS-EMOA [3].	17
3.1. Diagrama de flujo del HP-MOEA [19].	22
3.2. Ejemplo del operador de Cruce [19].	27
4.1. Gráfica de Ganancia vs Novedad extraída del trabajo original [19].	33
4.2. Gráfica de Ganancia vs Novedad de la implementación propia.	34
4.3. Comparación de Ganancia vs Novedad.	37
4.4. Frentes de Pareto comparativos (diferentes semilla, población de 50 individuos). . . .	39
4.5. Frentes de Pareto comparativos (diferentes semilla, población de 150 individuos). . .	39
4.6. Frentes de Pareto comparativos (diferentes semilla, población de 200 individuos). . .	40
4.7. Frentes de Pareto comparativos (misma semilla, población de 50 individuos).	40
4.8. Frentes de Pareto comparativos (misma semilla, población de 150 individuos).	41
4.9. Frentes de Pareto comparativos (misma semilla, población de 200 individuos).	41

Índice de cuadros

2.1. Ejemplos de compañías que usan sistemas de recomendación [1]	5
2.2. Objetivos de distintos modelos de sistemas de recomendación [1]	9
2.3. Resumen de trabajos relacionados con MOEA en sistemas de recomendación	20
4.1. Entorno de ejecución	31
4.2. Parámetros de ejecución del HP-MOEA	31
4.3. Errores cuadráticos medios del filtrado colaborativo en función del número de vecinos.	32
4.4. Comparación de hipervolumen entre el trabajo original y la implementación propia del HP-MOEA.	33
4.5. Resultados de GD e IGD obtenidos en la implementación propia.	34
4.6. Comparación de métricas entre el algoritmo HP-MOEA original y la versión modificada.	38
4.7. Hipervolumen promedio y desviación estándar del algoritmo original y modificado para distintos tamaños de población, con diferentes y mismas semillas.	38

Acrónimos y símbolos

IA Inteligencia Artificial

SR Sistemas de Recomendación

CF Filtrado Colaborativo

MF Factorización de Matriz

MOO Optimización Multiobjetivo

AE Algoritmos Evolutivos

AG Algoritmos Genéticos

MOEA Algoritmos Evolutivos Multiobjetivo

HP-MOEA Hybrid Probabilistic Multiobjective Evolutionary Algorithm

NSGA-II Nondominated Sorting Genetic Algorithm II

SMS-EMOA S-Metric Selection Evolutionary Multiobjective Algorithm

λ Probabilidad genética

HV Hipervolumen

GD Generational Distance

IGD Inverted Generational Distance

IEEE Instituto de Ingenieros Eléctricos y Electrónicos

Capítulo 1

Introducción

En los últimos años el término *inteligencia artificial* (IA) ha cobrado una gran relevancia, tanto en el ámbito académico como en el comercial. Aunque parezca un fenómeno reciente, muchos de estos sistemas que buscan y replican patrones ya se encontraban presentes en nuestra vida cotidiana e influyen silenciosamente en nuestras decisiones. Un ejemplo destacado son los sistemas de recomendación, ampliamente utilizados en redes sociales, servicios de *streaming* y plataformas de comercio, los cuales determinan en gran medida qué consumimos, vemos o adquirimos diariamente [1].

Los sistemas de recomendación (SR) son herramientas que predicen qué ítems serán de interés para un usuario, a partir de sus preferencias históricas o del comportamiento de usuarios similares [1]. Además de personalizar la experiencia, constituyen un pilar estratégico para las empresas digitales modernas, se estima que entre el 10 % y el 25 % de los ingresos de compañías de *streaming* y comercio electrónico provienen directamente de la efectividad de sus SR [14]. Esto refleja la relevancia de estas tecnologías no solo en la interacción con los usuarios, sino también en el modelo de negocio que las sustenta.

A pesar de su impacto, los SR enfrentan grandes desafíos como el inicio frío (*cold start*), la escasez de datos y la falta de diversidad en las recomendaciones [16]. En particular, los ítems nuevos también conocidos como *newcomers*, tienden a ser ignorados por los métodos tradicionales, reduciendo la capacidad del sistema de explorar nuevas alternativas [19]. Para abordar estas limitaciones, resulta necesario explorar enfoques híbridos que combinen filtrado colaborativo, técnicas basadas en contenido y algoritmos evolutivos multiobjetivo, buscando mejorar el equilibrio entre ganancia y novedad.

Frente a estos desafíos se desarrolla el presente trabajo de fin de grado, orientado al diseño e implementación de una extensión del algoritmo *Hybrid Probabilistic Multiobjective Evolutionary Algorithm* (HP-MOEA) [19]. Este algoritmo integra filtrado colaborativo basado en usuarios con un esquema evolutivo multiobjetivo que optimiza simultáneamente la ganancia (*profit*) y la novedad (*novelty*). La propuesta de mejora presentada incorpora un componente basado en contenido que pondera la métrica de novedad según la afinidad temática entre usuarios e ítems, con el fin de favorecer la inclusión de *newcomers* relevantes y mejorar el balance entre ganancia y novedad.

1.1. Objetivos

Objetivo general

Diseñar, implementar y evaluar una extensión del algoritmo HP-MOEA [19] que incorpore un componente basado en contenido para ponderar la métrica de novedad según la afinidad temática entre el usuario y el ítem. El objetivo es mejorar el balance entre ganancia y novedad, con especial énfasis en la selección de *newcomers* relevantes.

Objetivos específicos

1. Replicar el algoritmo HP-MOEA original y validar su desempeño mediante métricas para evaluar la calidad del frente de Pareto:
 - **Hipervolumen (HV):** medir el volumen cubierto por las soluciones no dominadas.
 - **Generational Distance (GD):** cuantificar la distancia promedio entre las soluciones obtenidas y el frente de Pareto óptimo.
 - **Inverted Generational Distance (IGD):** evaluar la cobertura del frente obtenido sobre el frente de referencia.
2. Incorporar información de contenido para modificar la función objetivo de novedad, ponderando por la relevancia temática usuario-ítem.
3. Comparar el algoritmo modificado contra el HP-MOEA original utilizando las métricas HV, GD e IGD, con el fin de determinar el impacto de la ponderación temática sobre el equilibrio entre ganancia y novedad [19].

1.2. Hipótesis

Se plantea la siguiente hipótesis de investigación:

Al ponderar la métrica de novedad por la afinidad temática usuario-ítem, el frente de Pareto generado por HP-MOEA presentará una calidad superior o equivalente a la del algoritmo original, reflejada en resultados iguales o mejores en las tres métricas de evaluación: Hipervolumen (HV), *Generational Distance* (GD) e *Inverted Generational Distance* (IGD).

1.3. Metodología resumida

La metodología seguida incluye:

- Revisión bibliográfica sobre SR y algoritmos evolutivos multiobjetivos.
- Replicación del algoritmo HP-MOEA como *baseline* sobre el dataset MovieLens.
- Construcción de perfiles de usuario basados en contenido.
- Modificación del objetivo de novedad, ponderando los *newcomers* según afinidad temática usuario–ítem.
- Evaluación comparativa del HP-MOEA original y la versión modificada utilizando HV, GD e IGD, con análisis estadísticos.

1.4. Organización del trabajo

El documento se estructura en cinco capítulos, organizados de manera que se facilite la comprensión progresiva del problema, los fundamentos teóricos, el algoritmo base, la implementación de la propuesta y las conclusiones finales:

- **Capítulo 1 – Introducción:** Presenta el contexto general, la motivación del estudio, los objetivos de la investigación y la estructura del documento.
- **Capítulo 2 – Marco teórico:** Expone los conceptos fundamentales sobre sistemas de recomendación, problemas de optimización multiobjetivo y algoritmos evolutivos, sirviendo de base conceptual para la propuesta.
- **Capítulo 3 – HP-MOEA:** Explica en detalle el funcionamiento del algoritmo original propuesto por Wei et al. [19], describiendo cómo combina filtrado colaborativo con un enfoque evolutivo multiobjetivo para optimizar simultáneamente ganancia y novedad.
- **Capítulo 4 – Implementación y algoritmo propuesto:** Presenta la implementación realizada del algoritmo HP-MOEA. Además, se describe la modificación introducida al algoritmo original y se muestran los resultados experimentales obtenidos en la comparación entre ambas versiones.
- **Capítulo 5 – Conclusiones:** Resume los principales hallazgos de la investigación y plantea posibles líneas de trabajo futuro.

Capítulo 2

Marco teórico

En este capítulo se presentan los fundamentos teóricos que sustentan el trabajo. Primero se introducen los Sistemas de Recomendación (SR), describiendo sus componentes esenciales, objetivos, formulaciones principales y los distintos enfoques utilizados, incluyendo los modelos basados en contenido, filtrado colaborativo e híbridos. También se revisan los problemas más conocidos de los SR, así como una breve reseña histórica y los avances más recientes en la industria y la academia.

Posteriormente, se aborda la Optimización Multiobjetivo, explicando su formulación matemática, los conceptos de frente de Pareto y dominancia, así como los indicadores de calidad más empleados en la literatura. Dentro de este marco se describen los Algoritmos Genéticos y los Algoritmos Evolutivos Multiobjetivo (*MOEA*), destacando en particular los algoritmos *NSGA-II* y *SMS-EMOA*, que constituyen la base de la metodología utilizada en este trabajo.

Finalmente, se presentan los trabajos relacionados, que representan el estado del arte en la aplicación de algoritmos evolutivos multiobjetivo a los sistemas de recomendación, y que sirven de referencia para posicionar la propuesta desarrollada en este trabajo.

2.1. Sistemas de recomendación

Los sistemas de recomendación (SR) constituyen una clase de herramientas computacionales que intentan predecir qué ítems serán de interés para un usuario, a partir de la información disponible en el sistema o entorno donde se está aplicando y de los patrones observados en las interacciones previas de los usuarios [1]. Su finalidad principal es personalizar la experiencia de uso, incrementando la relevancia del contenido mostrado y mejorando con ello la satisfacción, la fidelización y la interacción dentro del sistema [14]. En términos generales, un sistema de recomendación se estructura a partir de tres componentes principales [1]:

1. **Usuarios:** individuos que interactúan con la plataforma y generan información a través de calificaciones, compras, visualizaciones o cualquier otra forma de retroalimentación explícita o implícita.
2. **Ítems:** productos o contenidos disponibles en la plataforma, que pueden ser tanto de naturaleza física (ropa, electrodomésticos, automóviles, entre otros) como digital (películas, música, libros electrónicos, *Software*, etc.).

Sistema	Producto recomendado
Amazon.com	Libros y otros productos
Netflix	Video en streaming
GroupLens	Noticias
MovieLens	Películas
last.fm	Música
Google News	Noticias
Google Search	Publicidad
Facebook	Amigos, Publicidad
Pandora	Música
YouTube	Videos en línea
Tripadvisor	Productos de viaje
IMDb	Películas

Cuadro 2.1: Ejemplos de compañías que usan sistemas de recomendación [1]

3. **Calificaciones:** expresiones del nivel de preferencia del usuario hacia un ítem. Pueden ser explícitas, cuando el usuario proporciona directamente su valoración (puntuaciones en estrellas, votos positivos o negativos), o implícitas, cuando se infieren de su comportamiento (historial de compras, tiempo de visualización, clics).

El auge de la *Web* como medio para transacciones electrónicas y la creciente disponibilidad de grandes volúmenes de datos han impulsado significativamente el desarrollo de esta tecnología. La facilidad con que los usuarios pueden expresar sus preferencias, ya sea a través de calificaciones directas o mediante su comportamiento de consumo, ha sido un catalizador fundamental para la consolidación de los SR [1].

En la actualidad, compañías líderes del comercio electrónico y del entretenimiento digital han convertido los sistemas de recomendación en un componente estratégico de sus servicios. La incorporación de recomendaciones personalizadas no solo facilita el descubrimiento de productos, sino que también constituye una ventaja competitiva, al añadir una nueva dimensión en la experiencia del usuario y contribuir a la lealtad hacia la plataforma [14].

El campo del entretenimiento es uno de los entornos donde los SR han demostrado mayor impacto. Los usuarios tienden a consumir contenido multimedia y suelen estar dispuestos a valorar explícitamente su nivel de satisfacción. Esto genera bases de datos masivas, que pueden ser analizadas para identificar patrones y realizar recomendaciones con alto grado de personalización [14]. Algunos ejemplos de sistemas de recomendación ampliamente utilizados en la industria del entretenimiento y otros dominios se presentan en el Cuadro 2.1.

Formulación del problema de recomendación

El problema que los sistemas de recomendación buscan resolver puede formularse de dos formas principales [1]:

1. **Predicción de valor:** consiste en estimar la calificación que un usuario otorgaría a un ítem en particular. El problema se representa mediante una matriz de valoraciones, en la cual solo una parte de las entradas está disponible, y el sistema debe predecir las entradas faltantes. Esta formulación se conoce también como *matrix completion* y constituye la base de numerosos enfoques de recomendación.
2. **Recomendación de los mejores k ítems (top- k):** en este caso, el objetivo no es necesariamente predecir el valor exacto de una calificación, sino generar un conjunto ordenado de ítems más relevantes para un usuario específico. Esta formulación responde de manera más directa a las expectativas de los usuarios en entornos reales, donde lo que se requiere es recibir un número limitado de opciones personalizadas, sin necesidad de conocer todas las valoraciones.

Tipos de calificación en Sistemas de recomendación

Las preferencias de los usuarios pueden captarse de forma explícita o implícita, y la elección influye en el diseño del sistema de recomendación [1].

1. **Calificaciones explícitas:** proporcionadas directamente por el usuario.
 - Por intervalos: valores en una escala predefinida, como las 5 estrellas en *IMDb* o reseñas de hoteles.
 - Binarias: opciones de gusto/no gusto, como *like/dislike* o *upvote/downvote*.
2. **Calificaciones implícitas:** se infieren del comportamiento del usuario sin necesidad de interacción consciente. Ejemplos: historial de compras en *Amazon*, tiempo de reproducción en *YouTube* o artículos leídos en páginas de noticias.

Las calificaciones explícitas ofrecen mayor precisión pero requieren esfuerzo, mientras que las implícitas permiten recolectar más datos aunque con menor exactitud. En la práctica, muchos sistemas combinan ambas para mejorar el rendimiento [1].

2.1.1. Objetivos

El objetivo principal de un sistema de recomendación es incrementar la utilidad de la plataforma tanto para los usuarios como para los proveedores de servicios. Desde la perspectiva empresarial, los SR contribuyen a aumentar ventas, fidelidad y retención [14]. Desde la perspectiva del usuario, mejoran la experiencia de interacción, facilitando el descubrimiento de ítems relevantes y reduciendo la sobrecarga de información [1].

De manera más específica, los objetivos operativos y técnicos que persiguen los sistemas de recomendación son los siguientes [1]:

1. **Relevancia:** Constituye el objetivo primario de cualquier SR. Implica recomendar ítems que resulten útiles y atractivos para el usuario en función de sus preferencias previas. La relevancia determina la probabilidad de aceptación de las recomendaciones y constituye la base de la satisfacción del usuario.
2. **Novedad:** Se refiere a la capacidad del sistema de presentar ítems que el usuario no haya consumido anteriormente. Una recomendación deja de ser novedosa si simplemente reproduce elementos ya conocidos o excesivamente populares, lo que limita el descubrimiento de nuevas opciones y reduce la diversidad en el consumo.
3. **Serendipia:** Relacionada con la novedad, pero distinta en su naturaleza. La serendipia implica ofrecer ítems inesperados pero agradables, que sorprendan positivamente al usuario y despierten intereses latentes. Por ejemplo, recomendar un producto de una categoría que el usuario no había explorado previamente pero que resulta compatible con sus gustos puede ampliar su horizonte de preferencias.
4. **Diversidad:** Hace referencia a la variedad de ítems dentro de una lista de recomendaciones. Si todas las sugerencias son demasiado similares, aumenta el riesgo de que el usuario no encuentre nada atractivo. La diversidad incrementa la probabilidad de acierto y evita la monotonía, asegurando que las recomendaciones mantengan el interés a lo largo del tiempo.
5. **Incremento de ventas o interacción:** Aunque los objetivos anteriores se centran en la experiencia del usuario, desde la perspectiva de los proveedores el propósito central es aumentar la conversión en ventas o el nivel de participación dentro de la plataforma. Los SR logran este objetivo al facilitar el descubrimiento de productos relevantes y al estimular el consumo en áreas novedosas, lo que a su vez mejora la lealtad y la rentabilidad del sistema.

En conjunto, estos objetivos no son excluyentes, pero sí presentan tensiones inherentes. Por ejemplo, maximizar la relevancia puede reducir la novedad, mientras que priorizar la serendipia puede sacrificar exactitud en el corto plazo. El diseño de un SR robusto requiere encontrar un equilibrio entre estos objetivos, considerando tanto la satisfacción inmediata del usuario como los beneficios estratégicos de largo plazo [1].




Figura 2.1: Ejemplo de filtrado colaborativo basado en usuarios [14].

2.1.2. Modelos básicos de los Sistemas de recomendación

Los modelos de sistemas de recomendación pueden clasificarse en varias categorías fundamentales, que han evolucionado con el tiempo para abordar diferentes limitaciones.

SR basado en contenido Este enfoque recomienda ítems en función de las características que los describen, comparando dichas propiedades con el perfil de preferencias del usuario. Por ejemplo, en un sistema de películas se utilizan atributos como género, director o actores principales. Su principal ventaja es que puede recomendar nuevos ítems sin depender de las valoraciones de otros usuarios, aunque tiende a la sobreespecialización [1].

Filtrado colaborativo El filtrado colaborativo (FC) se fundamenta en la idea de que los usuarios con comportamientos similares en el pasado tenderán a coincidir también en el futuro [1, 9, 14]. Existen tres variantes principales:

1. **Basado en usuarios:** compara usuarios entre sí para recomendar ítems que usuarios similares ya han consumido.
2. **Basado en ítems:** encuentra relaciones entre ítems y recomienda aquellos que son similares a los consumidos por el usuario.
3. **Basado en modelos:** utiliza técnicas de aprendizaje automático para generalizar patrones en la matriz usuario-ítem.

Enfoque	Objetivo conceptual	Entrada
Filtrado Colaborativo	Recomendar en función de las valoraciones y acciones de usuarios con preferencias similares	Valoraciones de usuarios y valoraciones de la comunidad
Basado en contenido	Recomendar en función de las características de los ítems que el usuario ha valorado positivamente en el pasado	Valoraciones de usuarios y atributos de los ítems

Cuadro 2.2: Objetivos de distintos modelos de sistemas de recomendación [1]

El método de filtrado colaborativo basado en usuarios se ilustra en la Figura 2.1. En este enfoque, Joe valora positivamente tres películas y el sistema identifica usuarios con gustos similares para recomendarle ítems adicionales. Así, se sugieren películas como *Saving Private Ryan* y *Dune* [14].

Los enfoques colaborativo y basado en contenido, junto con sus objetivos conceptuales y entradas principales, se resumen en el Cuadro 2.2. Una formulación importante es la relación con el análisis de valores faltantes, ya que la matriz usuario-ítem suele estar incompleta y el objetivo del sistema es estimar las entradas desconocidas. Entre los enfoques más exitosos se encuentran los métodos de factorización de la matriz, que descomponen la matriz usuario-ítem en representaciones latentes de usuarios e ítems, permitiendo capturar patrones complejos con alta precisión [1, 14].

Otros modelos Incluyen técnicas menos convencionales como sistemas basados en conocimiento, algoritmos de clustering o enfoques inspirados en algoritmos evolutivos y redes neuronales [1].

Modelos híbridos Combinan dos o más de los enfoques anteriores para aprovechar sus ventajas y reducir sus limitaciones. Ejemplos comunes son la integración de filtrado colaborativo con modelos basados en contenido, o el uso de factorización de matrices con redes neuronales profundas [1].

2.1.3. Problemas conocidos

A pesar de los avances logrados, los sistemas de recomendación presentan limitaciones que siguen siendo objeto de estudio. Tanto en la academia como en la industria se investigan de manera constante estrategias para afrontar estos problemas y mitigar su impacto en escenarios reales [1, 13].

Inicio frío El problema de *cold start* surge cuando se incorporan nuevos usuarios o ítems al sistema. En ausencia de evaluaciones previas, resulta difícil estimar sus preferencias, lo que limita la precisión de las recomendaciones iniciales [1, 16].

Sinonimia La sinonimia ocurre cuando un mismo ítem es representado con diferentes nombres o descripciones. Esta ambigüedad impide que el sistema identifique correctamente que se trata del mismo elemento, generando redundancias o recomendaciones inconsistentes.

Privacidad Para ofrecer recomendaciones personalizadas, los sistemas necesitan recolectar y procesar información sensible de los usuarios. Esto plantea preocupaciones sobre la privacidad y la seguridad de los datos, obligando a implementar mecanismos de protección y generar confianza en los usuarios.

Escalabilidad Los sistemas deben gestionar un volumen creciente de datos provenientes de millones de usuarios e ítems. El desafío de la escalabilidad exige algoritmos capaces de operar de manera eficiente en grandes bases de datos distribuidas, manteniendo precisión y tiempos de respuesta adecuados.

Latencia La latencia se presenta cuando nuevos ítems no pueden ser recomendados hasta recibir suficientes evaluaciones. Este retraso afecta la capacidad del sistema de incorporar contenido reciente. Enfoques como el filtrado colaborativo combinado con técnicas basadas en categorías se utilizan para mitigar este problema.

En conjunto, estos desafíos motivan el desarrollo de modelos híbridos y enfoques avanzados que buscan mejorar la robustez y la capacidad de adaptación de los sistemas de recomendación [1].

2.1.4. Breve historia y actualidad de los Sistemas de recomendación

Esta sección constituye únicamente una reseña histórica destinada a contextualizar al lector sobre el origen, evolución y situación actual de los sistemas de recomendación (SR) tradicionales, sin abordar aún técnicas más recientes como los algoritmos evolutivos multiobjetivo (MOEA).

Los primeros antecedentes de los SR se remontan a inicios de la década de 1990. Belkin y Croft diferenciaron entre *information retrieval* y *information filtering*, siendo este último la base de los SR modernos. En 1992, Goldberg et al. presentaron *Tapestry*, considerado el primer SR de filtrado colaborativo [10].

Poco después, investigadores del MIT y la Universidad de Minnesota desarrollaron *GroupLens*, un sistema de recomendación de noticias integrando filtrado colaborativo basado en usuarios. Este proyecto dio origen al famoso laboratorio *GroupLens*, pionero en el área. En 1997 lanzaron el dataset *MovieLens* y ha servido de base para la publicación de múltiples conjuntos de datos [11].

A mediados de los 2000, la competencia *Netflix Prize* (2006–2009) marcó un hito en el campo. Gracias a ella, los modelos de factorización de matrix demostraron superar a los enfoques clásicos en términos de precisión y capacidad de modelar factores latentes [14].

Desde 2016, los SR han adoptado de manera creciente arquitecturas de *deep learning*. En la industria destacan modelos como *Wide&Deep* (Google), *DeepFM*, *YouTubeDNN* [6], que han potenciado la recomendación en plataformas a gran escala. En el ámbito académico, surgieron propuestas como *NeuralCF*, *NFM* y *CVAE*, consolidando el uso de redes neuronales en tareas de predicción de preferencias [9].

En la actualidad, nuevas líneas de investigación buscan mejorar la equidad, interpretabilidad y robustez de los SR. Entre ellas se encuentran los enfoques basados en inferencia causal y los modelos de recomendación de última generación aplicados por grandes plataformas como *TikTok*, que exploran arquitecturas avanzadas para modelar secuencias de interacción de los usuarios y maximizar la personalización en entornos dinámicos [18].

2.2. Optimización multiobjetivo con algoritmos evolutivos

2.2.1. Optimización Multiobjetivo

La optimización multiobjetivo (Multi-Objective Optimization, MOO) es una rama de la optimización matemática que busca resolver problemas en los que se persiguen simultáneamente varios objetivos que suelen estar en conflicto entre sí. A diferencia de la optimización monoobjetivo, no existe una única solución óptima, sino un conjunto de soluciones que representan diferentes compromisos entre los objetivos planteados [15]. Estos problemas se pueden formular de la siguiente manera:

$$\begin{aligned} \text{mín } f_m(x), \quad m &= 1, \dots, M, \\ \text{s.a. } g_j(x) &\leq 0, \quad j = 1, \dots, J, \\ h_k(x) &= 0, \quad k = 1, \dots, K, \\ x_i^L &\leq x_i \leq x_i^U, \quad i = 1, \dots, N. \end{aligned} \tag{2.1}$$

donde $x = (x_1, \dots, x_N)$ representa el vector de variables de decisión, $f_m(x)$ las funciones objetivo (M en total), $g_j(x)$ y $h_k(x)$ las restricciones de desigualdad y de igualdad respectivamente, y x_i^L, x_i^U los límites inferior y superior de cada variable [17].

Dominancia y Frente de Pareto

En un problema de optimización multiobjetivo, una solución x se dice que domina a otra solución x' si se cumple que:

$$f_i(x) \leq f_i(x') \quad \forall i \in \{1, \dots, M\}, \quad \exists j \in \{1, \dots, M\} : f_j(x) < f_j(x'), \tag{2.2}$$

es decir, x no es peor en ninguno de los objetivos y es estrictamente mejor en al menos uno de ellos [15].

El conjunto de soluciones que no son dominadas por ninguna otra dentro del espacio de búsqueda constituye el denominado frente de Pareto. Dicho frente representa los compromisos entre los distintos objetivos [15].




Figura 2.2: Frente de Pareto en un problema multiobjetivo. [20]

En la Figura 2.2 se ilustra el concepto de frente de Pareto. Los puntos P_1 y P_2 representan soluciones no dominadas, es decir, ninguna de ellas es mejor que la otra en todos los objetivos de manera simultánea. Estas soluciones conforman el frente de Pareto. En contraste, el punto P_3 y aquellos que se encuentran en la región T son dominados, dado que existe al menos una solución en el frente que mejora sus valores en todos los objetivos. La noción de dominancia permite así identificar qué soluciones son relevantes al momento de analizar los compromisos entre objetivos en conflicto.

Indicadores de Calidad

Para cuantificar objetivamente la calidad de las soluciones obtenidas, se emplean métricas que permiten comparar distintos algoritmos de optimización multiobjetivo. Supongamos que varios algoritmos generan diferentes frentes de Pareto, mediante estas métricas es posible evaluar cuál de ellos logra una mejor aproximación, distribución y cobertura del frente óptimo teórico.

1. **Hipervolumen (HV):** mide el volumen del espacio en el plano de objetivos que está simultáneamente dominado por las soluciones obtenidas y limitado por un punto de referencia predefinido. Un mayor valor de HV indica que el conjunto de soluciones no solo se aproxima mejor al frente de Pareto, sino que además logra cubrirlo de forma más uniforme.
2. **Generational Distance (GD):** calcula la distancia euclídea media desde cada solución obtenida hacia el frente de Pareto verdadero. Su valor refleja el grado de convergencia: mientras menor sea el GD, más cerca están las soluciones generadas de la frontera óptima.

3. **Inverted Generational Distance (IGD):** a diferencia del GD, mide la distancia promedio desde cada punto del frente de Pareto verdadero hacia el conjunto de soluciones obtenidas. Esta métrica evalúa simultáneamente la convergencia (qué tan cerca están las soluciones) y la cobertura (qué tan bien se distribuyen para representar toda la frontera).

Estos indicadores se han consolidado en la literatura como herramientas estándar para la evaluación de algoritmos evolutivos multiobjetivo, ya que permiten cuantificar tanto la convergencia hacia el frente de Pareto como la diversidad de las soluciones generadas [15]. Una discusión más detallada sobre este aspecto se presenta en la sección 2.2.3.

2.2.2. Algoritmos genéticos

Los algoritmos evolutivos (AE) constituyen una familia de métodos de optimización inspirados en la teoría de la evolución darwiniana, utilizando principios como la selección natural, la reproducción y la mutación para guiar la búsqueda de soluciones. Dentro de esta familia, los algoritmos genéticos (AG) representan un enfoque particular que incorpora además conceptos de la genética biológica, tales como cromosomas, genes y operadores de variación [17]. Estos algoritmos se clasifican como *metaheurísticas estocásticas*, es decir, métodos generales de búsqueda que no garantizan la obtención de la solución óptima real, pero que resultan eficaces para aproximarse a ella en problemas de alta complejidad [4]. Su carácter estocástico implica el uso de aleatoriedad en procesos como la selección de padres, el cruce o la mutación, lo que favorece la exploración del espacio de soluciones y reduce el riesgo de quedar atrapado en óptimos locales. Por estas razones, son ampliamente aplicados en escenarios donde los métodos deterministas resultan inviables [15].

Un AG típico sigue un flujo de ejecución que incluye inicialización de una población de individuos, evaluación mediante una función de aptitud, selección de padres, aplicación de operadores genéticos (cruce y mutación) para generar descendencia y, finalmente, supervivencia de los más aptos hasta cumplir un criterio de parada [3, 8]. Este flujo se representa en la Figura 2.3

Población e individuos

La población es el conjunto de posibles soluciones que el algoritmo mantiene en cada iteración, estas soluciones se conocen como individuos. Cada individuo se representa mediante un cromosoma, que codifica una solución candidata al problema. Esta representación puede ser binaria, entera, real u otras, dependiendo del dominio del problema. La diversidad de la población es un factor importante, ya que evita la convergencia prematura hacia soluciones subóptimas y permite explorar múltiples regiones del espacio de búsqueda [15].




Figura 2.3: Ciclo típico de un algoritmo genético [2].

Operadores genéticos

Los operadores genéticos son los mecanismos que introducen variación y permiten la exploración del espacio de soluciones.

Cruce: consiste en combinar partes de dos individuos (padres) para generar nuevos individuos (hijos). Existen diferentes esquemas, como cruce de un punto, de dos puntos o uniforme, donde se selecciona aleatoriamente la posición de corte y se intercambian segmentos cromosómicos. El cruce favorece la exploración, al combinar información existente para producir soluciones potencialmente mejores [17].

Mutación: altera de manera aleatoria uno o varios genes de un individuo, con baja probabilidad. Su función es mantener la diversidad genética de la población e introducir soluciones no alcanzables solo mediante cruce. Aunque suele aplicarse con baja frecuencia, resulta esencial para escapar de óptimos locales y explorar nuevas regiones del espacio de búsqueda [17].

Supervivencia

La supervivencia está determinada por la función de aptitud (*fitness function*), que asigna un valor de calidad a cada individuo según su capacidad para resolver el problema planteado. Esta función guía el proceso de selección, de modo que los individuos con mayor aptitud tengan mayor probabilidad de ser elegidos como padres y transmitir sus características a la siguiente generación [15]. En este sentido, la función de aptitud actúa como un mecanismo de presión selectiva que orienta la búsqueda hacia soluciones cada vez más prometedoras [17].

2.2.3. Algoritmos evolutivos multiobjetivos

Los Algoritmos Evolutivos Multiobjetivo (*MOEA*, por sus siglas en inglés) constituyen una extensión de los algoritmos evolutivos tradicionales, diseñados para resolver problemas con múltiples objetivos en conflicto [4]. A diferencia de la optimización mono-objetivo, donde la meta es encontrar una única mejor solución, en un escenario multiobjetivo se busca aproximar un conjunto de soluciones no dominadas que conforman la frontera de Pareto [15]. Estos algoritmos se apoyan en la naturaleza poblacional de los métodos evolutivos para explorar simultáneamente diferentes regiones del espacio de búsqueda, permitiendo mantener un equilibrio entre convergencia hacia la frontera y diversidad de soluciones [17].

Entre los *MOEA* más influyentes en la literatura se destacan *NSGA-II* [8] y *SMS-EMOA* [3], los cuales han marcado un estándar en la investigación y aplicación de la optimización multiobjetivo.

NSGA-II

El algoritmo NSGA-II (Non-dominated Sorting Genetic Algorithm II) fue propuesto por Deb et al. [8] como una versión mejorada del NSGA original. Su objetivo principal es ofrecer un método eficiente para aproximar la frontera de Pareto mediante una estrategia elitista que asegura la preservación de las mejores soluciones. El funcionamiento de NSGA-II se basa en tres componentes fundamentales:

1. **Ordenamiento no dominado rápido (Fast Non-dominated Sorting):** la población se clasifica en diferentes frentes de Pareto según la dominancia. El primer frente contiene las soluciones no dominadas, el segundo aquellas dominadas solo por las del primero, y así sucesivamente.
2. **Distancia de hacinamiento (Crowding Distance):** dentro de cada frente, se calcula una medida de densidad relativa que favorece la diversidad en la población. Esto evita la concentración excesiva de soluciones en una misma región de la frontera.
3. **Selección elitista:** se genera una población combinada de padres e hijos y, a partir de ella, se seleccionan los mejores individuos utilizando la clasificación por frentes y la distancia de hacinamiento. Este mecanismo asegura que las soluciones no dominadas de alta calidad se mantengan generación tras generación.




Figura 2.4: Procedimiento del NSGA-II [8].

Gracias a estos mecanismos, NSGA-II logra un balance entre convergencia hacia la frontera de Pareto y diversidad, manteniendo además una complejidad computacional reducida de $O(MN^2)$, donde M es el número de objetivos y N el tamaño de la población [8]. Este procedimiento se muestra en la Figura 2.4

SMS-EMOA

El algoritmo SMS-EMOA (S-Metric Selection Evolutionary Multiobjective Algorithm) fue introducido por Beume, Naujoks y Emmerich [3] con el propósito de integrar directamente un indicador de calidad en el proceso de selección. En particular, utiliza el hipervolumen dominado (también conocido como S-metric) como criterio central de selección. El procedimiento se caracteriza por:

1. **Algoritmo en estado estacionario:** en cada iteración se genera un solo descendiente mediante operadores genéticos y luego se decide qué individuo eliminar de la población para mantener su tamaño constante.
2. **Ordenamiento no dominado:** al igual que en NSGA-II, se aplica un ordenamiento por frentes de Pareto para estructurar la población.
3. **Selección basada en contribución al hipervolumen:** dentro del peor frente, se elimina el individuo con menor contribución exclusiva al hipervolumen. Esto garantiza que la población mantenga o aumente el volumen dominado, favoreciendo la convergencia y una distribución uniforme de las soluciones sobre la frontera.

El uso explícito del hipervolumen como medida de desempeño permite que SMS-EMOA se enfoque directamente en el objetivo final de muchos problemas multiobjetivo: obtener un conjunto de soluciones que cubra de manera representativa la frontera de Pareto. Este enfoque ha mostrado ventajas en términos de calidad de aproximación, especialmente en problemas con dos o tres objetivos, aunque con un costo computacional mayor debido al cálculo del hipervolumen [3].




Figura 2.5: Procedimiento del SMS-EMOA [3].

En la Figura 2.5 se muestra un ejemplo del criterio de selección en SMS-EMOA basado en la contribución exclusiva al hipervolumen. Las soluciones y_8 y y_9 pertenecen al segundo frente de Pareto R_2 . El área resaltada en turquesa corresponde al volumen del espacio objetivo cubierto por estas soluciones. Las zonas rayadas representan regiones dominadas por otros puntos, lo que reduce la relevancia de y_8 y y_9 . Aunque ambas soluciones se encuentran en el mismo frente, y_8 aporta un mayor incremento al hipervolumen, por lo que su eliminación resultaría más perjudicial para la diversidad y cobertura de la frontera que la de y_9 .

2.3. Trabajos relacionados

Los sistemas de recomendación basados en optimización multiobjetivo han progresado en la última década. A continuación, se describen en mayor profundidad los trabajos más representativos, que conforman el *state-of-the-art* en la aplicación de algoritmos evolutivos multiobjetivo (MOEA) a sistemas de recomendación. La comparación de estos trabajos se resumen en el Cuadro 2.3

A hybrid recommendation system with many-objective evolutionary algorithm [5], publicado en 2020 en *Applied Soft Computing* (Elsevier), presenta un sistema de recomendación híbrido que combina filtrado colaborativo (usuarios e ítems) y basado en contenido. El aporte central es el uso del algoritmo evolutivo *Reference Vector Guided Evolutionary Algorithm* (RVEA), diseñado para problemas con más de tres objetivos. El modelo busca optimizar simultáneamente precisión, diversidad, novedad y cobertura. Los experimentos, realizados sobre el dataset MovieLens y comparados contra NSGA-II y MOEA/D, muestran que RVEA obtiene una mejor distribución de soluciones en la frontera de Pareto, logrando listas de recomendación más equilibradas. Una innovación importante es la incorporación de vectores de referencia que guían la convergencia hacia regiones del espacio objetivo poco exploradas, favoreciendo soluciones con mayor diversidad y cobertura. La principal limitación identificada es el coste computacional al incrementar el número de objetivos, aunque se mantiene dentro de un rango aceptable para aplicaciones prácticas.

An improved matrix factorization based model for many-objective optimization recommendation [7], publicado en 2021 en *Information Sciences* (Elsevier), propone el modelo MaORA-IMF (*Many-objective Optimization Recommendation Algorithm with Improved Matrix Factorization*). Su diseño es de dos capas: en la inferior se aplica una factorización de matrices mejorada que añade restricciones de regularización para forzar diversidad y novedad, además de la precisión tradicional; en la superior se emplea una versión modificada de NSGA-III, optimizando simultáneamente precisión, recall, diversidad y novedad [7]. Este planteo evita la inconsistencia típica de los modelos de dos capas clásicos, donde la predicción de ratings y la optimización de listas responden a objetivos distintos. El uso de NSGA-III con puntos de referencia asegura que se mantenga presión de selección aun en escenarios con cuatro objetivos, un reto para MOEAs convencionales. Las pruebas sobre MovieLens-100k demuestran mejoras significativas respecto a baselines clásicos y modelos multiobjetivo de dos objetivos, especialmente en la recomendación de ítems de la larga cola. La contribución más destacada es la incorporación explícita de restricciones de novedad y diversidad en la capa de factorización, lo que fortalece la sinergia entre las dos etapas.

Multi-objective item evaluation for diverse as well as novel item recommendations [12], publicado en 2019 en *Expert Systems with Applications* (Elsevier), parte de la idea de que la excesiva especialización de los SR reduce la satisfacción de los usuarios. El trabajo introduce un marco denominado NewCrossPMOEA que integra: (i) un modelo de similitud no lineal extendido mediante el coeficiente de Bhattacharyya, que supera limitaciones de medidas tradicionales como coseno o Pearson en casos de alta dispersión de ratings; y (ii) un operador de cruce multi-parental NewCross, que preserva tanto la frecuencia como el orden relativo de los genes en la recombinación [12]. Con este enfoque, se evalúan las predicciones con filtrado colaborativo usuario-ítem y luego se filtran las listas candidatas mediante NSGA-II considerando dos objetivos: precisión y diversidad. Los experimentos sobre MovieLens demuestran que se obtienen listas con mayor novedad y diversidad sin sacrificar significativamente la precisión. El aporte técnico más importante es el operador de cruce, que garantiza que las listas recomendadas reflejen tanto la frecuencia de aparición de ítems en soluciones previas como su relevancia posicional, evitando pérdidas de información durante el proceso evolutivo.

Personalized Recommendation Based on Evolutionary Multi-Objective Optimization [21], publicado en 2015 en *IEEE Computational Intelligence Magazine*, constituye un trabajo pionero en la formalización de la recomendación personalizada como un problema de optimización multiobjetivo [21]. El modelo propuesto, denominado MOEA-ProbS, combina el algoritmo Probabilistic Spreading (ProbS) como estimador de precisión con la métrica de cobertura como indicador de diversidad. NSGA-II se aplica para evolucionar poblaciones de listas de recomendación optimizando ambos objetivos en paralelo. Una de las innovaciones metodológicas es la codificación conjunta de múltiples usuarios en un solo individuo, lo que permite generar en una única corrida múltiples listas para distintos perfiles, mejorando la eficiencia. Para reducir el coste computacional, los usuarios se agrupan previamente en clusters mediante k-means. Los resultados en MovieLens muestran que el enfoque supera a técnicas tradicionales de filtrado colaborativo en diversidad sin degradar severamente la precisión. Este trabajo sentó las bases para que posteriores investigaciones extendieran los objetivos a más dimensiones.

A Hybrid Probabilistic Multiobjective Evolutionary Algorithm for Commercial Recommendation Systems (HP-MOEA) [19], publicado en 2021 en la revista *Electronics* (MDPI), propone un sistema de recomendación híbrido orientado explícitamente a escenarios comerciales [19]. Combina filtrado colaborativo basado en usuarios con algoritmos evolutivos multiobjetivo, integrando versiones modificadas de NSGA-II y SMS-EMOA. Los objetivos optimizados son el *profit* (ganancia esperada) y la *novelty* (novedad). El *profit* se define como la suma del producto entre la probabilidad de aceptación de un ítem y su beneficio económico, mientras que la *novelty* corresponde al número de ítems nuevos (*newcomers*) incluidos en la lista de recomendación. La motivación es clara: en sistemas comerciales, maximizar ingresos es prioritario, pero ignorar ítems nuevos limita la exploración y la sostenibilidad del catálogo. El algoritmo produce una frontera de Pareto con diferentes soluciones que representan distintos equilibrios entre maximizar beneficios y explorar nuevos productos.

Título del trabajo	Año	Modelo básico de SR usado	MOEA usado	Objetivos a optimizar	Observación
A hybrid recommendation system with many-objective evolutionary algorithm[5]	2020	Filtrado colaborativo basado en usuarios, ítems y contenido	RVEA	Precisión, Diversidad, Novedad, Cobertura	Sistema híbrido que combina tres técnicas de SR y balancea simultáneamente múltiples métricas.
An improved matrix factorization based model for many-objective optimization recommendation[7]	2021	Factorización de matriz (modificado)	NSGA-III (modificado)	Precisión, Memoria (recall), Diversidad, Novedad	Modelo de dos capas con factorización de matrices mejorada y NSGA-III modificado, con mejor cobertura de ítems de la larga cola.
Multi-objective item evaluation for diverse as well as novel item recommendations[12]	2019	Filtrado colaborativo (modificado)	NSGA-II	Precisión, Novedad	Introduce operador de cruce y métrica de similitud mejorada para recomendaciones más diversas y novedosas.
Personalized Recommendation Based on Evolutionary Multi-Objective Optimization[21]	2015	Filtrado colaborativo basado en usuarios	NSGA-II	Precisión, Diversidad	Plantea la recomendación personalizada como problema multiobjetivo; NSGA-II genera listas diversas y precisas en un solo proceso.
A Hybrid Probabilistic Multiobjective Evolutionary Algorithm for Commercial Recommendation Systems (HP-MOEA)[19]	2021	Filtrado colaborativo basado en usuarios	NSGA-II y SMS-EMOA (modificados)	Ganancias, Novedad	Algoritmo híbrido que optimiza simultáneamente ganancias y novedad en un contexto comercial.

Cuadro 2.3: Resumen de trabajos relacionados con MOEA en sistemas de recomendación

Capítulo 3

HP-MOEA

Los sistemas de recomendación tradicionales presentan limitaciones como el problema de inicio frío [16], donde nuevos ítems ingresan al sistema sin calificaciones suficientes para ser recomendados de manera efectiva. Para afrontar este desafío, Wei et al. proponen el algoritmo *Hybrid Probabilistic Multiobjective Evolutionary Algorithm* (HP-MOEA) [19], el cual constituye un sistema de recomendación híbrido de carácter comercial. Este modelo integra técnicas de filtrado colaborativo y optimización evolutiva multiobjetivo para equilibrar los intereses de usuarios y proveedores.

El proceso inicia con un filtrado colaborativo basado en usuarios, utilizado para estimar calificaciones iniciales de los ítems que los usuarios aún no han valorado. Posteriormente, se aplica un algoritmo evolutivo multiobjetivo (MOEA) que optimiza de manera simultánea dos objetivos en conflicto: ganancia, orientado a maximizar las beneficios del proveedor, y novedad, enfocado en promover la recomendación de ítems nuevos y así mitigar el inicio frío.

Para lograr este equilibrio, HP-MOEA introduce operadores genéticos adaptados al dominio de la recomendación y combina ideas de dos algoritmos evolutivos multiobjetivo clásicos: *NSGA-II* [8] y *SMS-EMOA* [3]. Esta integración permite mantener la diversidad de soluciones y garantizar una convergencia adecuada hacia la frontera de Pareto, proporcionando un conjunto de recomendaciones que balancean utilidad y exploración. El flujo de ejecución del HP-MOEA se puede observar en la Figura 3.1.

3.1. Filtrado colaborativo basado en usuarios

El filtrado colaborativo (*Collaborative Filtering*, CF) es una de las técnicas más utilizadas en los sistemas de recomendación. Su objetivo es predecir qué ítems pueden ser de interés para un usuario, basándose en las valoraciones realizadas previamente por otros usuarios con comportamientos similares [14].

Sea U el conjunto de usuarios e I el conjunto de ítems. Se define una matriz de valoraciones $R \in \mathbb{R}^{|U| \times |I|}$ que almacena las calificaciones que los usuarios asignan a los ítems. En la práctica, esta matriz es altamente dispersa, ya que los usuarios solo califican un subconjunto reducido de los ítems disponibles. Por tanto, el problema principal consiste en predecir las valoraciones faltantes y generar recomendaciones a partir de ellas. Para ello, se construye una matriz de valoraciones predichas $\tilde{R} \in \mathbb{R}^{|U| \times |I|}$, que contiene la estimación de las calificaciones para los ítems no evaluados por los usuarios.




Figura 3.1: Diagrama de flujo del HP-MOEA [19].

El enfoque del filtrado colaborativo basado en usuarios (*User-Based CF*) es calcular primero la similitud entre usuarios. Dado un usuario u con vector de valoraciones $\mathbf{r}_u$, la similitud con otro usuario v puede medirse con la similitud coseno:

$$\text{sim}_{u,v} = \frac{\mathbf{r}_u \cdot \mathbf{r}_v}{\|\mathbf{r}_u\| \cdot \|\mathbf{r}_v\|} \quad (3.1)$$

A partir de esta medida, se selecciona el conjunto $s_{u,k}$ de los k vecinos más similares a u . Entonces, la predicción de la valoración de u para un ítem i , denotada como $\tilde{r}_{u,i}$, se calcula como un promedio ponderado de las valoraciones otorgadas por los vecinos:

$$\tilde{r}_{u,i} = \frac{\sum_{v \in s_{u,k}} \text{sim}_{u,v} \cdot r_{v,i}}{\sum_{v \in s_{u,k}} \text{sim}_{u,v}} \quad (3.2)$$

De esta forma, el sistema puede recomendar al usuario u aquellos ítems con mayor valor en $\tilde{R}$, es decir, los que tienen las calificaciones predichas más altas.

El principal problema de este enfoque clásico es que, ante la aparición de nuevos ítems (*newcomers*), al no existir información disponible sobre ellos, el filtrado colaborativo basado en usuarios tiende a ignorarlos. Para abordar esta limitación, Wei et al. proponen excluir los *newcomers* en esta primera etapa y considerar únicamente aquellos ítems con información suficiente, dejando el tratamiento específico de los nuevos ítems para las etapas posteriores del algoritmo.

3.2. MOEA

Los Algoritmos Evolutivos Multiobjetivo (*Multi-Objective Evolutionary Algorithms*, MOEA) extienden los principios de los algoritmos evolutivos tradicionales para resolver problemas en los que deben optimizarse simultáneamente varios objetivos en conflicto [3]. En lugar de buscar una única solución óptima, los MOEA producen un conjunto de soluciones no dominadas que aproximan la *frontera de Pareto*, permitiendo al tomador de decisiones seleccionar aquella que mejor se ajuste a sus necesidades [8].

3.2.1. Objetivos

En el contexto de sistemas de recomendación comerciales, no basta con maximizar la precisión de las recomendaciones; también resulta esencial considerar métricas como la ganancia y la novedad. Estos objetivos suelen estar en conflicto: recomendar ítems altamente populares tiende a maximizar la precisión y el beneficio inmediato, mientras que incluir ítems nuevos (*newcomers*) aporta diversidad y resuelve el problema del inicio frío, aunque pueda reducir la precisión a corto plazo [19].

Ganancia esperada total (*Total Expected Profit*)

La función de ganancia esperada mide el beneficio que un sistema de recomendación puede obtener al recomendar un conjunto de ítems. Considera tanto la probabilidad de aceptación del usuario como el beneficio asociado a cada ítem. Dado un usuario u y un ítem i , si $\tilde{r}_{u,i}$ es la valoración predicha y $\tilde{r}_{\max}$ el valor máximo posible, y p_i representa la ganancia asociada a i , la ganancia esperada de i para u se define como:

$$\rho_{u,i} = \frac{\tilde{r}_{u,i}}{\tilde{r}_{\max}} \times p_i. \quad (3.3)$$

El beneficio total del sistema para todos los usuarios U y sus listas de recomendación I_u se expresa como:

$$P_e = \sum_{u \in U} \sum_{i \in I_u} \rho_{u,i}. \quad (3.4)$$

Para las pruebas experimentales, se adoptó un sistema de calificaciones binario basado en *like* o *dislike* para determinar si la recomendación fue aceptada por el usuario. En este enfoque, si la calificación de una película es igual o superior a 3 se marca como *like*, y en caso contrario se marca como *dislike* [19].

El valor de las ganancias comerciales (*profit*) se deriva de la tasa de aceptación de los ítems y se correlaciona positivamente con la cantidad de veces que un elemento es aceptado. De este modo, una película obtiene un *profit* cercano a 10 si fue aceptada el 100 % de las veces, mientras que su *profit* se aproxima a 1 cuando no fue aceptada en ninguna ocasión [19]. Este comportamiento se expresa mediante la siguiente ecuación:

$$p_i = 1 + 9 \times \frac{\sum_{c=1}^n I(r_c \geq 3)}{n}, \quad (3.5)$$

donde n es el total de calificaciones de la película i , r_c es la calificación c de la película i , e I es la función indicadora que devuelve 1 cuando la condición se cumple y 0 en caso contrario.

Novedad (*Novelty*)

El segundo objetivo es fomentar la inclusión de ítems nuevos en las recomendaciones. Estos ítems, denominados *newcomers*, carecen de historial de valoraciones y, por tanto, no pueden ser tratados de la misma forma que los ítems tradicionales. Para cada usuario u , se define N_u como el número de *newcomers* presentes en su lista de recomendaciones. Así, la función de novedad se formula como:

$$N = \sum_{u \in U} N_u. \quad (3.6)$$

Maximizar la novedad garantiza que las listas de recomendación contengan una mayor proporción de ítems nuevos, lo cual no solo contribuye a resolver el problema del inicio frío, sino que también incrementa la capacidad del sistema de sorprender al usuario y diversificar las recomendaciones.

Normalización

Para que los objetivos de ganancia y novedad tengan la misma escala e impacto en métricas como la distancia de hacinamiento y la contribución al hipervolumen, se aplica un proceso de normalización. Este consiste en dividir los valores de cada función objetivo por sus respectivos valores máximos, de manera que queden acotados en el rango $[0, 1]$.

Sea P_e la ganancia total definida en la ecuación 3.4 y P_M la ganancia máxima alcanzable, la versión normalizada se expresa como:

$$P_e^{norm} = \frac{P_e}{P_M}. \quad (3.7)$$

De manera análoga, sea N la novedad definida en la ecuación 3.6 y N_M la máxima novedad posible, la forma normalizada se formula como:

$$N^{norm} = \frac{N}{N_M}. \quad (3.8)$$

El cálculo de P_M y N_M requiere obtener los individuos máximos de ganancia y novedad, procedimiento que se describe en la sección 3.2.2.

3.2.2. Individuos y población

En el marco de HP-MOEA, cada solución candidata al problema de recomendación se representa como un individuo. El conjunto de individuos conforma la población, la cual evoluciona a lo largo de las iteraciones del algoritmo mediante operadores genéticos como selección, cruce y mutación.

Un individuo se codifica como una matriz de tamaño $|U| \times L$, donde cada fila corresponde a la lista de recomendaciones de un usuario $u \in U$, y cada columna representa un ítem asignado. De este modo, un individuo agrupa las listas de recomendación de todos los usuarios del sistema. Para evitar redundancias, en cada fila no pueden existir ítems duplicados ni ítems que el usuario ya haya calificado previamente.

$$\text{Individuo} = \begin{bmatrix} i_{1,1} & i_{1,2} & \cdots & i_{1,L} \\ i_{2,1} & i_{2,2} & \cdots & i_{2,L} \\ \vdots & \vdots & \ddots & \vdots \\ i_{|U|,1} & i_{|U|,2} & \cdots & i_{|U|,L} \end{bmatrix} \quad (3.9)$$

Individuos máximos

Para la inicialización, HP-MOEA considera dos individuos especiales, denominados individuos máximos, que representan los valores extremos de cada objetivo:

- **Individuo de máxima ganancia** (P_M): contiene, para cada usuario, los L ítems con mayor beneficio esperado, calculado a partir de la predicción de calificaciones y la ganancia asociada a cada ítem.
- **Individuo de máxima novedad** (N_M): se construye seleccionando, para cada usuario, los L ítems *newcomers*, maximizando así la función objetivo de novedad.

Estos individuos extremos cumplen un rol fundamental en el proceso de normalización de objetivos en la sección 3.2.1 y, además, son incluidos en la población inicial como puntos de referencia que guían la dirección evolutiva del algoritmo. El resto de los individuos de la población inicial se generan de forma aleatoria, garantizando así diversidad en la exploración del espacio de soluciones.

3.2.3. Operadores genéticos

Los operadores genéticos de HP-MOEA son los responsables de generar nuevos individuos a partir de la población existente. En particular, se emplean los operadores de cruce y mutación, adaptados al dominio de los sistemas de recomendación.

Cruce

El operador de cruce diseñado para HP-MOEA se basa en un esquema uniforme, en el que la probabilidad genética de herencia depende de la calidad relativa de los padres. El proceso se realiza fila por fila de la matriz de recomendaciones:

1. El individuo hijo hereda directamente los genes (ítems) que aparecen en ambos padres.
2. Para los genes restantes, se calcula una probabilidad genética $\lambda(A, B)$ en función de las métricas del algoritmo evolutivo en uso:

- En NSGA-II, $\lambda(A, B)$ depende del rango de no-dominancia y de la distancia de hacinamiento:

$$\lambda(A, B) = \begin{cases} \frac{\text{rank}(B)}{\text{rank}(A) + \text{rank}(B)}, & \text{si } \text{rank}(A) \neq \text{rank}(B) \\ \frac{\text{dist}(A)}{\text{dist}(A) + \text{dist}(B)}, & \text{en otro caso} \end{cases} \quad (3.10)$$

- En SMS-EMOA, $\lambda(A, B)$ se calcula considerando el rango, la contribución al hipervolumen ϕ y, en su defecto, el número de individuos dominantes d :

$$\lambda(A, B) = \begin{cases} \frac{\text{rank}(B)}{\text{rank}(A) + \text{rank}(B)}, & \text{si } \text{rank}(A) \neq \text{rank}(B) \\ \frac{\phi(A)}{\phi(A) + \phi(B)}, & \text{si } \phi(A), \phi(B) \text{ disponibles} \\ \frac{d(B)}{d(A) + d(B)}, & \text{en otro caso} \end{cases} \quad (3.11)$$

3. Para cada posición restante, se genera un número aleatorio $r \in [0, 1]$. Si $r < \lambda(A, B)$, el gen se hereda de A; en caso contrario, se hereda de B.

De esta manera, los padres con mayor calidad evolutiva tienen mayor probabilidad de transmitir sus características al hijo, guiando la población hacia regiones más prometedoras de la frontera de Pareto. El procedimiento completo del operador de cruce se muestra en el Algoritmo 1.

La Figura 3.2 muestra un ejemplo de aplicación del operador de cruce. El gen común en ambos padres (02) es heredado directamente por el hijo. Para el segundo gen, el número aleatorio generado es 0,6, menor a la probabilidad genética $\lambda(A, B) = 0,7$, por lo que el hijo hereda el gen del padre A. En el tercer gen, el número aleatorio es 0,8, mayor que $\lambda(A, B)$, de modo que se hereda el gen del padre B. Finalmente, en la última posición el número aleatorio es 0,3, menor a $\lambda(A, B)$, por lo que el gen se hereda nuevamente del padre A.

Algorithm 1 Operador de cruce del HP-MOEA [19]

Entrada: Individuos padres A y B **Salida:** Individuo hijo S

```
1: Calcular la probabilidad genética  $\lambda(A, B)$ 
2: for  $i = 0$  to  $|U|$  do
3:   Pasar los genes comunes de  $A$  y  $B$  a  $S$ 
4:   while Número de genes heredados por  $S < L$  do
5:     if  $\text{rand}(0, 1) < \lambda(A, B)$  then
6:       Pasar el siguiente gen distintivo de  $A$  a  $S$ 
7:     else
8:       Pasar el siguiente gen distintivo de  $B$  a  $S$ 
9:     end if
10:  end while
11: end for
12: return  $S$ 
```




Figura 3.2: Ejemplo del operador de Cruce [19].

Mutación

El operador de mutación utilizado corresponde a la mutación de un solo punto. Para cada individuo, se selecciona aleatoriamente un gen (ítem en la lista de recomendaciones de un usuario). Si un número aleatorio $r \in [0, 1]$ es menor que la probabilidad de mutación P_m , dicho gen se reemplaza por un ítem distinto, cumpliendo dos restricciones:

1. No debe repetirse dentro de la misma lista de recomendaciones del usuario.
2. No puede corresponder a un ítem previamente calificado por el usuario.

Este operador introduce diversidad en la población y permite explorar nuevas combinaciones de recomendaciones que no estaban presentes en generaciones anteriores.

3.2.4. Bucle principal

El marco de evolución de HP-MOEA combina de manera adaptativa las ventajas de dos algoritmos evolutivos clásicos: *NSGA-II* y *SMS-EMOA*. El primero es uno de los marcos más utilizados en optimización multiobjetivo, cuya selección se basa en el rango de no-dominancia y la distancia de hacinamiento. Su principal fortaleza es la capacidad de generar rápidamente un conjunto de soluciones no dominadas y promover el hipervolumen en las primeras etapas de la evolución. Sin embargo, en etapas posteriores su avance se vuelve más lento y puede fluctuar debido a que la selección no está directamente ligada al hipervolumen.

Por otro lado, *SMS-EMOA*, un algoritmo basado en indicadores, utiliza la contribución exclusiva al hipervolumen como criterio de selección secundaria, lo que permite un crecimiento más estable del hipervolumen, aunque con menor velocidad en la exploración inicial.

En HP-MOEA se establece un punto de transición durante la evolución: antes de este punto se utiliza *NSGA-II* y, una vez alcanzado, se cambia a *SMS-EMOA*. De esta forma, se aprovecha la capacidad exploratoria inicial de *NSGA-II* y la estabilidad en la mejora del hipervolumen de *SMS-EMOA* en etapas posteriores. El punto de transición se determina cuando el valor máximo de hipervolumen no mejora durante μ generaciones consecutivas, siendo μ un parámetro ajustado experimentalmente. El procedimiento completo de HP-MOEA se detalla en el Algoritmo 2.

Análisis de complejidad La complejidad computacional de HP-MOEA está determinada principalmente por el proceso de búsqueda evolutiva. En la primera etapa, basada en *NSGA-II*, la operación de generación de nueva población (línea 6 del Algoritmo 2) tiene complejidad $O(N \cdot m^2 \cdot L)$, donde N es el tamaño de la población, m el número de usuarios y L el número de ítems recomendados. La operación de ordenamiento no dominado rápido (línea 7) presenta complejidad $O(N^2)$. Denotando por T_1 el número de generaciones bajo *NSGA-II*, la complejidad de esta etapa se aproxima a:

$$O(T_1 \cdot N \cdot m^2 \cdot L), \quad (3.12)$$

Algorithm 2 Procedimiento de HP-MOEA [19]

Entrada: Usuarios, ítems y calificaciones

Salida: Conjunto de soluciones R

```
1: Calcular las calificaciones predichas mediante User-Based-CF
2:  $R \leftarrow \emptyset$ ,  $mark \leftarrow 0$ ,  $i \leftarrow 0$ 
3: Inicializar una población  $P$  con  $N$  individuos
4: while la condición de terminación no se cumple do
5:   if  $mark = 0$  then
6:     Generar nueva población  $Q$  a partir de  $P$ 
7:     Seleccionar de  $P \cup Q$  los mejores  $N$  individuos vía NSGA-II para formar el nuevo  $P$ 
8:     if el hipervolumen de  $P$  es mayor al de  $R$  then
9:        $R \leftarrow P$ ,  $i \leftarrow 0$ 
10:    else if  $++i \geq \mu$  then
11:       $mark \leftarrow 1$ 
12:    end if
13:  else
14:    Generar un nuevo individuo  $q$  a partir de  $R$ 
15:     $R \leftarrow$  reducir un individuo de  $R \cup \{q\}$  vía SMS-EMOA
16:  end if
17: end while
18: return  $R$ 
```

En la segunda etapa, tras el punto de transición, HP-MOEA cambia a *SMS-EMOA*, donde en cada generación solo se produce un individuo. En este caso, las operaciones dominantes corresponden al ordenamiento no dominado y a la reducción de soluciones. En un espacio biobjetivo, sus complejidades son $O(N^2)$ y $O(N \cdot \log N)$, respectivamente. Denotando por T_2 el número de generaciones bajo *SMS-EMOA*, la complejidad de esta etapa es:

$$O(T_2 \cdot N^2). \quad (3.13)$$

Por lo tanto, la complejidad total del algoritmo HP-MOEA puede expresarse como:

$$O(T \cdot N \cdot m^2 \cdot L), \quad (3.14)$$

donde $T = T_1 + T_2$ representa el número total de generaciones ejecutadas.

Capítulo 4

Implementación y algoritmo propuesto

En este capítulo se describe el proceso de implementación del algoritmo *Hybrid Probabilistic Multiobjective Evolutionary Algorithm* (HP-MOEA) y la extensión propuesta para mejorar el tratamiento de los *newcomers*.

Primero se detalla el entorno experimental empleado, incluyendo el dataset *MovieLens*, las bibliotecas de software utilizadas y los parámetros de ejecución adoptados a partir del trabajo original de Wei et al. Luego se presentan los resultados obtenidos en la implementación base, mostrando que reproducen fielmente el desempeño reportado en la literatura, lo que valida la corrección de la implementación realizada.

A continuación, se identifican las limitaciones del enfoque original, en particular la definición de la métrica de novedad, que contabiliza únicamente la presencia de ítems nuevos sin considerar su relación con las preferencias de los usuarios. Para superar esta limitación se propone un ajuste que incorpora perfiles de usuarios basados en metadatos de contenido, técnica característica de los sistemas de recomendación basados en contenido [1], permitiendo ponderar la relevancia de los *newcomers* al calcular la novedad.

La modificación planteada se integra de manera ligera en el preprocesamiento y en la función objetivo de novedad, manteniendo inalterada la complejidad computacional general del algoritmo. Finalmente, se presentan los resultados experimentales que comparan el algoritmo original con la versión modificada, evidenciando un incremento sustancial en el hipervolumen alcanzado, sin deteriorar las métricas de convergencia y diversidad (GD e IGD). Estos hallazgos muestran que la incorporación de información de contenido mejora la calidad global de las recomendaciones generadas.

4.1. Implementación

Para la validación experimental se utilizó el dataset *MovieLens* [11], un conjunto de datos ampliamente empleado en la investigación de SR. *MovieLens* es mantenido por el *GroupLens Research Group* de la Universidad de Minnesota y contiene calificaciones explícitas otorgadas por usuarios a películas, en diferentes versiones desde 100.000 hasta 20 millones de valoraciones.

Componente	Especificación
CPU	AMD Ryzen 7 5700X3D, 8 núcleos / 16 hilos, 3.0 GHz base, 4.1 GHz boost, 100 MB caché total
Memoria RAM	2 × 16 GB DDR4 a 3200 MHz
Sistema Operativo	Windows 11
GPU	No se emplearon tecnologías de aceleración por GPU

Cuadro 4.1: Entorno de ejecución

Parametro	Valor	Descripción
L	10	Tamaño de la lista de recomendación por usuario
N	100	Cantidad de individuos en la población inicial (incluye individuos máximos)
T	3000	Número total de generaciones o iteraciones
p_m	$1/L$	Probabilidad de mutación
μ	500	Punto de transición del algoritmo (cambio de NSGA-II a SMS-EMOA)

Cuadro 4.2: Parámetros de ejecución del HP-MOEa

La implementación del algoritmo HP-MOEa se realizó en Python 3.12.4, utilizando las siguientes bibliotecas:

- **pymoo 0.6.1.3**: para ejecutar algoritmos evolutivos multiobjetivo como NSGA-II y SMS-EMOA.
- **matplotlib 3.9.0**: para la generación de gráficos.
- **NumPy 1.26.4** y **pandas 2.2.3**: para manejo de estructuras de datos y soporte en la interacción con *pymoo*.

Las pruebas se ejecutaron en la computadora personal del autor de este trabajo. Las especificaciones del entorno de hardware y software se detallan en el Cuadro 4.1.

Parámetros La configuración experimental del HP-MOEa siguió los mismos valores de parámetros definidos en el trabajo original de Wei et al. [19]. Estos parámetros se detallan en el Cuadro 4.2, donde se especifican los valores adoptados y su función dentro del algoritmo.

4.1.1. Análisis experimental del filtrado colaborativo

El primer componente del algoritmo HP-MOEa es el filtrado colaborativo basado en usuarios, cuya explicación teórica se presenta en la sección 3.1.

El parámetro principal de este método es la cantidad de vecinos considerados para estimar las calificaciones de los usuarios, denotado como k . Con el objetivo de determinar su valor óptimo, se realizó un análisis experimental.

Para ello, se empleó el conjunto de datos *MovieLens* completo, el cual se subdividió en dos partes: un conjunto de entrenamiento que representó el 80 % de los datos y un conjunto de prueba con el 20 % restante. Posteriormente, se evaluó el rendimiento del modelo variando el número de vecinos desde 5 hasta 35, en incrementos de 5. En cada caso, se calculó el error cuadrático medio (MSE) tanto sobre los datos de entrenamiento como sobre los de prueba. Cabe señalar que las calificaciones en el dataset *MovieLens* se encuentran en una escala discreta de 1 a 5, por lo que los valores de MSE deben interpretarse dentro de ese rango.

Los resultados obtenidos se presentan en la Cuadro 4.3, donde se observa la relación entre el número de vecinos y el desempeño del modelo.

Número de vecinos (k)	MSE Entrenamiento	MSE Prueba
5	0.93	1.22
10	0.91	1.26
15	0.89	1.27
20	0.88	1.27
25	0.87	1.27
30	0.87	1.27
35	0.86	1.27

Cuadro 4.3: Errores cuadráticos medios del filtrado colaborativo en función del número de vecinos.

Podemos observar que a medida que aumenta el número de vecinos k , el error cuadrático medio (MSE) sobre el conjunto de entrenamiento disminuye ligeramente, lo que indica un mejor ajuste a los datos conocidos. Sin embargo, el MSE sobre el conjunto de prueba aumenta progresivamente, evidenciando un fenómeno de sobreajuste: el modelo aprende demasiado de los usuarios más cercanos y pierde capacidad de generalización.

Considerando este comportamiento, se concluye que el valor óptimo de k es 10, ya que ofrece un equilibrio adecuado entre precisión en el entrenamiento y capacidad de generalización sobre datos no vistos.

4.1.2. Primeros resultados

En el trabajo original del HP-MOEA se utiliza el hipervolumen como métrica principal para evaluar el rendimiento del algoritmo evolutivo. El hipervolumen (HV) mide la porción del espacio objetivo que es dominada por un conjunto de soluciones, constituyéndose como una medida unaria capaz de indicar si un frente no dominado es superior a otro. Formalmente, se define en términos de la medida de Lebesgue [19] sobre el espacio objetivo:

$$HV(S) = \lambda \left(\bigcup_{x \in S} [f_1(x), z_1^r] \times \cdots \times [f_m(x), z_m^r] \right), \quad (4.1)$$

Fuente	Hipervolumen promedio	Desviación estándar
Trabajo original	0.51739	0.0011
Implementación propia	0.51738	0.0008
Diferencia	0.00001	—

Cuadro 4.4: Comparación de hipervolumen entre el trabajo original y la implementación propia del HP-MOEA.




Figura 4.1: Gráfica de Ganancia vs Novedad extraída del trabajo original [19].

donde $\lambda(\cdot)$ representa la medida de Lebesgue (longitud, área o volumen, según la dimensión), S es el conjunto de soluciones y $z^r = (z_1^r, \dots, z_m^r)$ corresponde al punto de referencia en el espacio objetivo, el cual es dominado por todas las soluciones del frente de Pareto verdadero. En los experimentos reportados, dicho punto de referencia se fija en $(0, 0)$.

Tras la implementación del HP-MOEA en este trabajo, los resultados obtenidos fueron muy cercanos a los reportados en el artículo original, lo que valida la corrección de la implementación realizada. La comparación se muestra en el Cuadro 4.4

Como puede observarse, la diferencia entre los valores de hipervolumen es de apenas 0,00001, lo que representa menos del 0,002 % respecto al valor original. Dicha variación se encuentra muy por debajo de la desviación estándar reportada, por lo que puede considerarse estadísticamente irrelevante.

A continuación, en la Figura 4.1 se presenta el gráfico de comparación entre ganancia y novedad obtenido en el trabajo original, junto con los resultados reportados por otros enfoques. Por su parte, la Figura 4.2 muestra los resultados obtenidos en la implementación realizada en el presente trabajo.




Figura 4.2: Gráfica de Ganancia vs Novedad de la implementación propia.

Además del hipervolumen, en este trabajo se proponen dos métricas adicionales para evaluar el rendimiento del algoritmo: la distancia generacional (*Generational Distance, GD*) y la distancia generacional inversa (*Inverted Generational Distance, IGD*).

La métrica *GD* mide la distancia promedio entre las soluciones obtenidas y el frente de Pareto verdadero, evaluando principalmente la convergencia. Por su parte, la métrica *IGD* calcula la distancia promedio desde los puntos del frente de Pareto verdadero hacia el conjunto de soluciones aproximadas, considerando simultáneamente convergencia y cobertura. En la implementación propia del HP-MOEA, los valores de estas métricas se resumen en el Cuadro 4.5.

Métrica	Promedio	Desviación estándar
GD	0.0010	0.0005
IGD	0.0047	0.0003

Cuadro 4.5: Resultados de GD e IGD obtenidos en la implementación propia.

4.2. Limitaciones del enfoque original

Tras implementar el algoritmo HP-MOEA descrito en el capítulo anterior, se identificó una limitación importante relacionada con el tratamiento de los *newcomers*. El enfoque original del algoritmo optimiza simultáneamente ganancia y novedad, permitiendo introducir ítems sin historial de calificaciones dentro de las listas de recomendación. Sin embargo, el cálculo de la novedad se limita a contabilizar la cantidad de ítems nuevos incluidos, sin discriminar si estos poseen alguna relación semántica con las preferencias del usuario.

En consecuencia, el algoritmo puede recomendar *newcomers* que resulten irrelevantes para el perfil del usuario, afectando negativamente la utilidad real de la recomendación. Este escenario es especialmente crítico en contextos como el dataset MovieLens, donde cada película cuenta con metadatos de contenido (por ejemplo, géneros cinematográficos) que no son aprovechados en la versión original del HP-MOEA.

El desafío identificado es, por tanto, integrar la dimensión de relevancia temática al objetivo de novedad, de modo que los *newcomers* no solo incrementen la diversidad del sistema, sino que además sean coherentes con los gustos históricos de los usuarios.

4.3. Perfiles de usuarios

Para superar esta limitación, se propone construir perfiles de usuarios basados en sus calificaciones históricas y la información de contenido de los ítems.

Cada usuario u cuenta con un vector de preferencias P_u , inferido a partir de la frecuencia y valoración otorgada a géneros de películas previamente consumidas. Por ejemplo, si un usuario ha calificado de manera positiva un alto número de películas de acción y ciencia ficción, su perfil reflejará una mayor afinidad hacia dichos géneros.

De esta forma, el perfil de cada usuario se convierte en una representación explícita de sus intereses, que puede ser utilizada para ponderar la selección de *newcomers*. Formalmente, si C_i es el vector binario de contenido que describe a un ítem i (ejemplo: pertenencia a géneros), la relevancia entre un usuario u y un ítem i se mide como la intersección ponderada entre P_u y C_i .

$$\text{Rel}(u, i) = \sum_{g \in G} P_u(g) \cdot C_i(g)$$

donde G representa el conjunto de géneros, $P_u(g)$ la preferencia de u por el género g , y $C_i(g)$ la pertenencia de la película i a dicho género.

Este valor de relevancia permite cuantificar hasta qué punto un *newcomer* está alineado con los intereses del usuario, ofreciendo un criterio adicional de calidad en la selección de ítems nuevos.

4.4. Modificación en la función objetivo

La propuesta consiste en redefinir la función objetivo de *novedad* del HP-MOEA, incorporando una ponderación que mida la afinidad entre los *newcomers* y los perfiles de los usuarios. La idea de utilizar perfiles de usuario contruidos a partir de metadatos de ítems proviene de los sistemas de recomendación basados en contenido [1].

Sin embargo, la aplicación concreta de este principio al cálculo de la función objetivo de novedad en el HP-MOEA constituye un aporte propio de este trabajo, por lo que no existen antecedentes directos en la literatura que lo referencien.

En lugar de contabilizar únicamente la cantidad de ítems nuevos en una lista de recomendación, la métrica de novedad ponderada considera tanto la presencia de *newcomers* como su relevancia temática.

Formalmente, para un usuario u y su lista de recomendación L_u , la novedad ponderada se define como:

$$\text{Novelty}^*(u) = \frac{1}{|G|} \sum_{i \in L_u \cap N} \text{Rel}(u, i) \quad (4.2)$$

donde N es el conjunto de *newcomers*, $\text{Rel}(u, i)$ es la relevancia definida en la sección anterior y $|G|$ corresponde al número total de géneros disponibles.

La función objetivo de novedad del HP-MOEA se reemplaza por esta versión ponderada, de modo que el algoritmo no solo maximiza la inclusión de ítems nuevos, sino también la probabilidad de que dichos ítems resulten interesantes para el usuario.

Adicionalmente, se redefine el *individuo máximo de novedad* (*max novelty individual*). En la versión original, este se construye seleccionando únicamente *newcomers* de forma indiscriminada, mientras que en la modificación se priorizan aquellos con mayor relevancia para cada usuario según su perfil de preferencias. Esto asegura que el extremo del frente de Pareto asociado a la novedad represente la mejor configuración posible en términos de afinidad temática, y no solo en cantidad absoluta de ítems nuevos. Con este ajuste se busca alcanzar un equilibrio más realista entre *ganancia* y *novedad*, aumentando la probabilidad de aceptación de los *newcomers* y reduciendo la posibilidad de recomendar elementos poco relevantes.

La modificación propuesta introduce cambios únicamente en la etapa de preprocesamiento de datos y en el cálculo del objetivo de novedad dentro del algoritmo. Ambos procesos adicionales presentan una complejidad de $O(m)$ y $O(1)$, respectivamente, donde m representa la cantidad de usuarios. La complejidad computacional del HP-MOEA modificado se mantiene igual, expresada como:

$$O(T \cdot N \cdot m^2 \cdot L), \quad (4.3)$$

4.5. Resultados

Tras la ejecución del algoritmo modificado se logró una mejora significativa en la métrica del hipervolumen. El algoritmo fue ejecutado un total de 30 veces, utilizando diferentes semillas aleatorias en cada corrida, y a partir de los resultados se calculó el valor promedio del hipervolumen junto con su desviación estándar.

El valor promedio obtenido para el algoritmo modificado fue de 0,5937, lo que representa un incremento aproximado del 14,75 % respecto al algoritmo original, que había alcanzado un valor promedio de 0,51738. Esta diferencia puede observarse en la Figura 4.3, donde en rojo se muestra el conjunto de soluciones no dominadas finales del algoritmo original y en azul las del algoritmo modificado. En este gráfico se representan las mejores soluciones no dominadas obtenidas a lo largo de las 30 ejecuciones, lo que permite visualizar de forma conjunta el comportamiento global de ambos enfoques.

La versión modificada cubre una mayor área del espacio objetivo en relación al punto (0, 0), lo que se traduce en un hipervolumen superior y, en consecuencia, en una mejor distribución de soluciones no dominadas. Además, una comparación detallada de las métricas entre ambas implementaciones se presenta en el Cuadro 4.6.




Figura 4.3: Comparación de Ganancia vs Novedad.

Métrica	Criterio	Original	Modificado
Hipervolumen (HV)	Mayor es mejor	0.51738 $\pm$ 0.0008	0.5937 $\pm$ 0.0008
Generational Distance (GD)	Menor es mejor	0.0010 $\pm$ 0.0005	0.0012 $\pm$ 0.0005
Inverted Generational Distance (IGD)	Menor es mejor	0.0047 $\pm$ 0.0003	0.0047 $\pm$ 0.0004

Cuadro 4.6: Comparación de métricas entre el algoritmo HP-MOEA original y la versión modificada.

En síntesis, los resultados muestran que el algoritmo modificado logra un hipervolumen considerablemente mayor sin afectar negativamente las métricas de distancia generacional (GD) e inversa (IGD), que se mantienen estables. Esto es positivo porque implica que el frente de Pareto obtenido conserva una buena proximidad y distribución respecto a la frontera óptima conocida, pero al mismo tiempo domina una mayor región del espacio objetivo.

4.6. Pruebas con distintos tamaños de población

Para completar las validaciones experimentales, se ejecutaron el algoritmo original y el modificado con tamaños de población de 50, 150 y 200. Cada configuración se evaluó en dos etapas: primero con 30 corridas independientes usando diferentes semillas aleatorias, y luego con 30 corridas adicionales empleando la misma semilla en cada par de ejecuciones, permitiendo así comparar los resultados bajo condiciones controladas. En todos los casos se reporta el hipervolumen promedio y su desviación estándar sobre las 30 ejecuciones.

Población	Diferentes semillas				Mismas semillas			
	HV (Orig.)	Desv.	HV (Mod.)	Desv.	HV (Orig.)	Desv.	HV (Mod.)	Desv.
50	0.5660	0.0010	0.5938	0.0008	0.5658	0.0009	0.5942	0.0007
150	0.5769	0.0004	0.5937	0.0006	0.5772	0.0005	0.5941	0.0005
200	0.5785	0.0003	0.5993	0.0004	0.5787	0.0004	0.5989	0.0003

Cuadro 4.7: Hipervolumen promedio y desviación estándar del algoritmo original y modificado para distintos tamaños de población, con diferentes y mismas semillas.

Los resultados obtenidos se presentan en el Cuadro 4.7, donde se observa una mejora consistente del hipervolumen en la versión modificada del algoritmo para todos los tamaños de población evaluados, tanto en las ejecuciones con diferentes semillas como en las que emplean las mismas semillas. Además, los gráficos incluidos más adelante muestran la comparación visual de los frentes de Pareto correspondientes a cada configuración, permitiendo apreciar con mayor claridad las diferencias en la calidad y distribución de las soluciones no dominadas.




Figura 4.4: Frentes de Pareto comparativos (diferentes semilla, población de 50 individuos).




Figura 4.5: Frentes de Pareto comparativos (diferentes semilla, población de 150 individuos).




Figura 4.6: Frentes de Pareto comparativos (diferentes semilla, población de 200 individuos).




Figura 4.7: Frentes de Pareto comparativos (misma semilla, población de 50 individuos).




Figura 4.8: Frentes de Pareto comparativos (misma semilla, población de 150 individuos).




Figura 4.9: Frentes de Pareto comparativos (misma semilla, población de 200 individuos).

Capítulo 5

Conclusiones

El presente trabajo abordó el diseño, implementación y evaluación de una extensión al algoritmo *Hybrid Probabilistic Multiobjective Evolutionary Algorithm* (HP-MOEA) aplicado a sistemas de recomendación. El desarrollo incluyó tanto la reproducción fiel del algoritmo original de Wei et al. [19] como la propuesta de una modificación orientada a mejorar el tratamiento de ítems *newcomers* mediante la incorporación de información basada en contenido.

En primer lugar, la implementación original permitió validar el comportamiento del HP-MOEA como un enfoque híbrido que combina filtrado colaborativo basado en usuarios con algoritmos evolutivos multiobjetivo (NSGA-II y SMS-EMOA), logrando un balance entre ganancia y novedad. Posteriormente, la modificación introducida ajustó el cálculo de la novedad, ponderando los ítems nuevos según su afinidad temática con los perfiles de usuario. Esta integración de contenido, aunque computacionalmente ligera, demostró ser efectiva en enriquecer la relevancia de las recomendaciones ofrecidas.

Los resultados experimentales muestran que la versión modificada mantiene valores estables en las métricas de distancia generacional (GD) e inversa (IGD), lo cual indica que la distribución de soluciones en la frontera de Pareto no se ve afectada negativamente. Al mismo tiempo, se observó una mejora significativa en el hipervolumen, aumentando de 0,51738 a 0,5937. Esta ganancia implica que el espacio de soluciones alcanzado es más amplio y diverso, permitiendo al sistema explorar compromisos más favorables entre objetivos en conflicto. En síntesis, se comprueba que es posible mejorar la calidad de las recomendaciones y abordar de manera más efectiva el problema de inicio frío al incorporar información de contenido, sin sacrificar el rendimiento global del modelo.

5.1. Trabajos futuros

A partir de lo realizado, se identifican varias líneas de investigación que pueden enriquecer y extender el presente trabajo:

- **Incorporación de más objetivos:** extender el modelo hacia un esquema *many-objective*, considerando métricas como diversidad, cobertura o serendipia, que permitan un análisis más integral del sistema.
- **Exploración de algoritmos evolutivos alternativos:** evaluar enfoques como MOEA/D, NSGA-III o algoritmos basados en indicadores, y comparar su desempeño frente a NSGA-II y SMS-EMOA.

- **Fuentes avanzadas de información de contenido:** utilizar descripciones textuales, metadatos enriquecidos o representaciones mediante *embeddings* obtenidos con técnicas de *deep learning*.
- **Evaluación en escenarios de mayor escala:** aplicar el algoritmo en datasets de gran volumen como MovieLens-20M o Amazon Reviews para analizar su escalabilidad y robustez en contextos reales.
- **Implementación en entornos productivos:** adaptar la propuesta a un sistema de recomendación en producción, evaluando su impacto tanto en métricas de negocio como en la experiencia de usuario.

Bibliografía

- [1] Charu C. Aggarwal. *Recommender Systems: The Textbook*. Cham, Switzerland: Springer, 2016. ISBN: 978-3-319-29657-9. DOI: 10.1007/978-3-319-29659-3. URL: <https://doi.org/10.1007/978-3-319-29659-3>.
- [2] Musatafa Abbas Albadr et al. «Genetic Algorithm Based on Natural Selection Theory for Optimization Problems». En: *Symmetry* 12.11 (2020). DOI: 10.3390/sym12111758. URL: <https://doi.org/10.3390/sym12111758>.
- [3] N. Beume, B. Naujoks y M. Emmerich. «SMS-EMOA: Multiobjective selection based on dominated hypervolume». En: *European Journal of Operational Research* 181.3 (2007), págs. 1653-1669. DOI: 10.1016/j.ejor.2006.08.008.
- [4] J. Blank y K. Deb. «pymoo: Multi-Objective Optimization in Python». En: *IEEE Access* 8 (2020).
- [5] Xingjuan Cai et al. «A hybrid recommendation system with many-objective evolutionary algorithm». En: *Expert Systems with Applications* 159 (2020). ISSN: 0957-4174. DOI: <https://doi.org/10.1016/j.eswa.2020.113648>. URL: <https://www.sciencedirect.com/science/article/pii/S0957417420304723>.
- [6] Paul Covington, Jay Adams y Emre Sargin. «Deep Neural Networks for YouTube Recommendations». En: *Proceedings of the 10th ACM Conference on Recommender Systems*. ACM, 2016, págs. 191-198. DOI: 10.1145/2959100.2959190.
- [7] Z. Cui et al. «An improved matrix factorization based model for many-objective optimization recommendation». En: *Information Sciences* 579 (2021). DOI: <https://doi.org/10.1016/j.ins.2021.07.077>.
- [8] K. Deb et al. «A fast and elitist multiobjective genetic algorithm: NSGA-II». En: *IEEE Transactions on Evolutionary Computation* 6.2 (2002).
- [9] Zhenhua Dong et al. «A Brief History of Recommender Systems». En: *Proceedings of ACM Conference (Conference'17)*. Accepted by DLP-KDD 2022. ACM, 2022.
- [10] David Goldberg et al. «Using collaborative filtering to weave an information tapestry». En: *Communications of the ACM* 35.12 (1992), págs. 61-70. DOI: 10.1145/138859.138867.
- [11] F. Maxwell Harper y Joseph A. Konstan. «The MovieLens Datasets: History and Context». En: *ACM Transactions on Interactive Intelligent Systems (TiiS)* 5.4 (dic. de 2015), 19:1-19:19. DOI: 10.1145/2827872. URL: <http://dx.doi.org/10.1145/2827872>.

- [12] Ankush Jain, Pramod Kumar Singh y Dhar Joydip. «Multi-objective item evaluation for diverse as well as novel item recommendations». En: *Expert Systems with Applications* 139 (2020). doi: 10.1016/j.eswa.2019.112857.
- [13] P. Karthikeyan y C. Tejasvini. «Review of Movie Recommendation System». En: *2022 8th International Conference on Advanced Computing and Communication Systems (ICACCS)*. IEEE, 2022. doi: 10.1109/ICACCS54159.2022.9785014.
- [14] Y. Koren, R. Bell y C. Volinsky. «Matrix factorization techniques for recommender systems». En: *Computer* 42.8 (oct. de 2009), págs. 30-37.
- [15] M. Kubat. *An Introduction to Machine Learning*. Springer, 2015. Cap. 13 The Genetic Algorithm.
- [16] Bleta Lika, Kostas Kolomvatsos y Stavros Hadjiefthymiades. «Facing the cold start problem in recommender systems». En: *Expert Systems With Applications* 41.4 (2014). doi: 10.1016/j.eswa.2013.09.005.
- [17] Christian Daniel von Lücken Martínez. «Algoritmos evolutivos para optimización multiobjetivo: un estudio comparativo en un ambiente paralelo asíncrono». Tesis de masterado. San Lorenzo, Paraguay: Universidad Nacional de Asunción, dic. de 2003.
- [18] Rui Shi et al. «IPS: Unified Profile Management for Ubiquitous Online Recommendations». En: *Proceedings of the VLDB Endowment* 13.12 (2020), págs. 3425-3438. doi: 10.14778/3415478.3415548.
- [19] Guijin Wei, Qinglong Wu y MengChu Zhou. «A Hybrid Probabilistic Multiobjective Evolutionary Algorithm for Commercial Recommendation Systems». En: *IEEE Transactions On Computational Social Systems* 8.3 (2021). doi: 10.1109/tcss.2021.3055823.
- [20] Wikipedia contributors. *Frente de Pareto*. <https://upload.wikimedia.org/wikipedia/commons/thumb/7/75/FrentePareto.svg/500px-FrentePareto.svg.png>. Accedido: 13 de septiembre de 2025. 2023.
- [21] Y. Zuo et al. «Personalized recommendation based on evolutionary multi-objective optimization [research frontier]». En: *IEEE Comput. Intell. Mag.* 10.1 (2015).